



SENAMHI

PISCO temperatura versión 1.1 (PISCOT v1.1)

SENAMHI-DHI 2018

Citar como:

Huerta, A.; Aybar, C.; Lavado-Casimiro, W. PISCO temperatura v.1.1. SENAMHI - DHI-2018, Lima-Perú

Introducción

Es cada vez más importante disponer de datos meteorológicos fiables para comprender las tendencias de las variables climáticas y los extremos climáticos, así como su impacto en los recursos hídricos y la agricultura. A pesar de eso, este tipo de información presenta ciertas debilidades cuando se realiza los diferentes análisis climáticos. El mayor problema de los datos de estaciones convencionales es la pobre distribución espacial y temporal de su información, esto sobretodo en la región de los Andes si comparamos con otras regiones a nivel global (Skansi et al., 2013). Por lo tanto, la creación de conjuntos de datos grillados mediante técnicas de interpolación que utilizan los valores de datos locales (es decir, registros de estaciones meteorológicas) permite estimar las características climatológicas de lugares o áreas donde no se dispone de mediciones (Dumitrescu y Birsan, 2015).

Para la variable temperatura (T), diferentes productos grillados a escala mensual han sido establecidos a nivel global y regional (Hansen et al., 2010; Morice et al., 2012). Sin embargo, bases a escalas más finas (espacial y temporal) representan un reto aún mayor debido a la necesidad de datos meteorológicos con mayor control de calidad y representatividad climática (homogeneizados) (Antolini et al., 2016; Bhaskar Rao et al., 2009; Caesar et al., 2006; Dumitrescu y Birsan, 2015; Haylock et al., 2008; Herrera et al., 2016; Hiebl y Frei, 2016; Xavier et al., 2015). Asimismo, se hace necesario el uso de imágenes satelitales para obtener una menor incertidumbre de estimación en zonas de poca o nula información convencional. La combinación de datos satelitales y datos observados es lo que se conoce como “merging” (combinación). Los trabajos de Kilibarda et al. (2014) y Oyler et al. (2015) son ejemplos de combinación para la construcción de bases grilladas de T a escala diaria con una resolución espacial de hasta 800m aproximadamente.

En este contexto, el SENAMHI ha comenzado a producir el producto PISCO (Peruvian Interpolation data of the SENAMHI's Climatological and hydrological Observations). En el presente reporte presentamos de manera resumida en qué consiste la nueva versión de PISCO temperatura versión 1.1 (PISCOT v1.1) el cual tiene un área de influencia nacional y datos diarios desde enero de 1981 hasta diciembre del 2016 a una resolución de ~10 km.

Datos de Ingreso

Para la generación de PISCOt v1.1 se utilizaron i) datos observados de temperatura del aire máxima (Tx) y mínima diaria (Tn), ii) el producto de temperatura de suelo (LST) del sensor MODIS (Moderate Resolution Imaging Spectroradiometer), y iii) predictores estáticos espaciales: Elevación (Z), Longitud (X), Latitud (Y) y el Índice de Disección Topográfica (TDI).

Los datos observados (en total 684 estaciones climatológicas) fueron obtenidos por el Servicio Nacional de Meteorología e Hidrología (SENAMHI). Estos datos fueron sometidos a tres principales procesos: i) control de calidad, ii) imputación y iii) homogeneización. El control de calidad fue automático y visual siguiendo los lineamientos de Aguilar et al. (2003) y Hunziker et al., (2018). La imputación de información hizo uso de los valores de T diaria de estaciones y datos de reanálisis del ERA-Interim (Tx y Tn) a través de un modelo estadístico basado en desviaciones de T (anomalías estandarizadas). Para la homogeneización se usó el algoritmo de Menne y Williams (2009) a escala mensual, y para las correcciones diarias se realizó una transformación de los factores mensuales a diarios (Vincent et al., 2002). De esta manera, luego del control de calidad de datos se usaron 178 series de tiempo (Tx y Tn) con al menos 15 años de datos que posteriormente fueron completados y homogeneizados en el periodo 1981-2016 (Figura 1).

Para observaciones de LST, se obtuvo información del MODIS a una escala temporal de 8 días y a resolución espacial de 1km. Este producto es el denominado: MYD11A2 (Wan et al., 2004). MYD11A2 estima LST utilizando la señal térmica infrarroja recibida por el sensor del MODIS y el algoritmo split-window que utiliza absorción diferencial en bandas infrarrojas adyacentes para corregir la atenuación atmosférica y la emisividades basadas en la clasificación de la cubierta terrestre para tener en cuenta la variabilidad de la emisividad superficial (Oyler et al., 2015). Se utilizó las imágenes día y noche del satélite como covariables de los valores de Tx y Tn respectivamente. MYD11A2 fue descargado de la página web del IRI Data Library (https://iridl.ldeo.columbia.edu/SOURCES/.USGS/.LandDAAC/.MODIS/.version_005/).

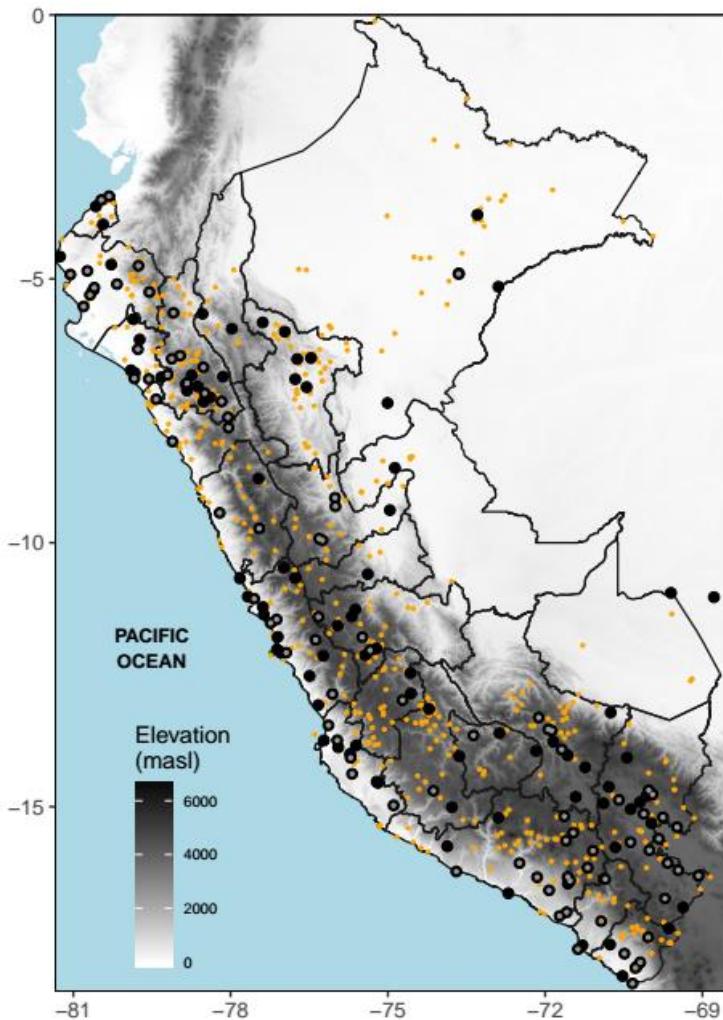


Figura 1. Distribución espacial de estaciones de Tx y Tn disponibles (684, anaranjado) y usadas (178, negro) para la construcción de PISCOt v1.1.

Información de Z fue obtenida del Global Multi-resolution Terrain Elevation Data 2010 a una resolución de 5km (GMTED, <https://lta.cr.usgs.gov/GMTED2010>), usada también en otro producto grillado de T mensual en Perú (VicSerr, Vicente-Serrano et al., 2018). Se usó GMTED ya que facilitaría la comparación entre PISCOt v1.1 y VicSerr, y el desarrollo de modelos que puede combinar ambas bases.

El TDI fue calculado según Holden et al. (2011a), usando el DEM:

$$TDI(s_0) = \sum_{i=1}^n \frac{Z(s_0) - Z_{min}(i)}{Z_{max}(i) - Z_{min}(i)}$$

Donde $TDI(s_0)$ es el valor final del TDI multi-escala para cada punto de grilla s_0 , $Z(S_0)$ es la elevación de un punto de grilla s_0 , Z_{min} es el valor mínimo de elevación en un punto de grilla en la ventana espacial i , Z_{max} es el valor máximo de elevación en un punto de grilla en la ventana espacial i , y n es el número de ventanas espaciales. El TDI para un tamaño de ventana espacial específico, refleja la altura de una celda relación con el terreno circundante y varía de 0 (más bajo que el terreno circundante) a 1 (más alto que el terreno circundante). El TDI varía de 0 a 5 ya que se calculó usando un total de 5 ventanas espaciales: 10, 15, 20, 25, 30 km. A pesar de que la selección es subjetiva, los tamaños de las ventanas tienen en cuenta las variaciones espaciales en el dominio de Perú, y mantienen una definición estática espacialmente del predictor TDI.

Debido a la diferentes resoluciones espaciales de las covariables (LST, Z, X, Y, TDI), estos fueron llevadas a una única resolución de 0.1° (Figura 2) y a la misma grilla de PISCO precipitación v2.1 (PISCOPE v2.1, Aybar et al. 2018).

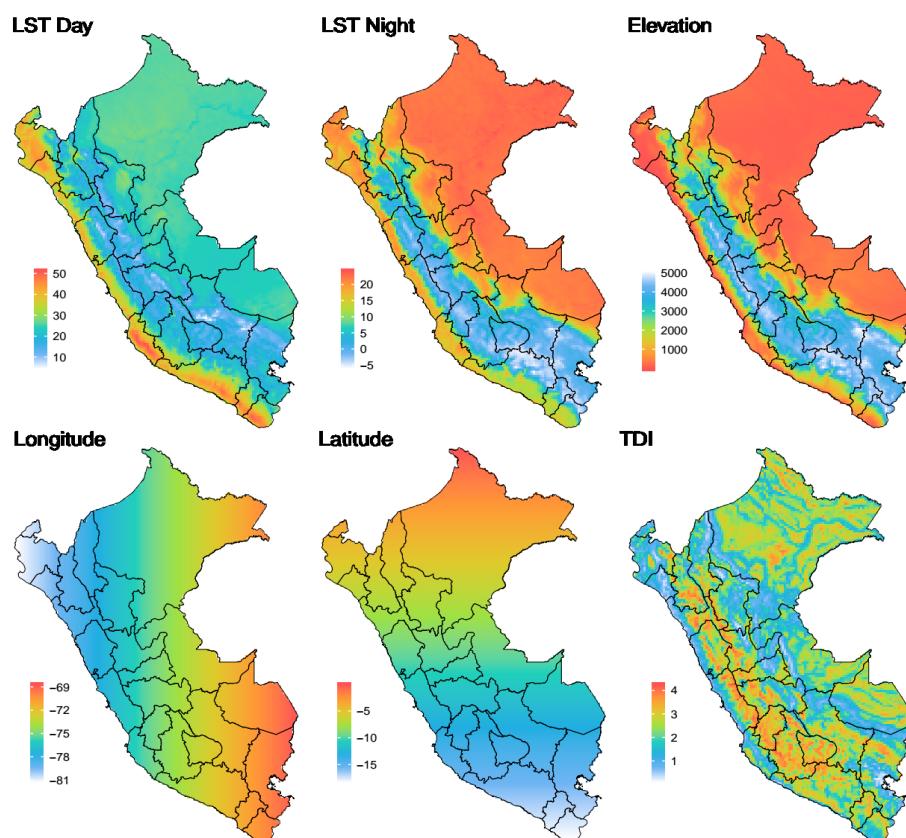


Figura 2. Covariables espaciales usadas para la construcción de PISCOt v1.1.

Estimación de temperatura

PISCOt v1.1 es el resultado de la combinación entre datos observados de estaciones climatológicas convencionales, datos satelitales (LST) y variables topográficas (Z, X, Y y TDI). El método de construcción de PISCOt v1.1 es climatológicamente asistido, y conlleva tres principales pasos. En primer lugar se hace una combinación a escala de normales climatológicas (nT); segundo, la interpolación de la anomalía mensual/diaria (dT) haciendo uso de la variación mensual de las normales ya mezcladas; y finalmente, la suma entre la normal grillada (G_nT) y anomalía grillada (G_dT) para la obtención de T. Este proceso es igual e independiente para Tx y Tn.

Para nT (1981-2010) se utilizó un método híbrido denominado Geographic Weighted Regression Kriging (GWRK), que toma en cuenta las variaciones en las relaciones espaciales al incorporar variaciones locales y agrega residuos de kriging para estimar T. El proceso es similar al Regression Kriging (RK), sin embargo, la regresión lineal ordinaria (OLS) es reemplazada por Geographic Weighted Regression (GWR) que considera la no-estacionariedad en el espacio. GWRK fue realizada entre T y tres covariables espaciales ($T = f(LST, X, Y, Z)$) para la construcción de G_nT.

En el caso de dT mensual/diaria (1981-2016), se hizo uso del Regression Splines (RSPLINES), similar a RK pero reemplazando el método estocástico Kriging por el determinístico Splines. Primeramente, dT fue relacionado mediante OLS usando como covariable G_nT ($dt = f(G_{nt})$), luego los residuales fueron interpolados con X, Y TDI usando Splines ($residual_dT = f(X, Y, TDI)$). Una vez hecho lo anterior, se combinaron y se obtuvo G_dT.

El último paso fue simplemente agregar G_dT y G_nT, dando como resultado PISCOt v1.1. A manera de ejemplo, el flujo de trabajo para la temperatura grillada del 04/02/1982 es descrita (Figura 3): La G_nT es construida mediante GWRK usando la climatología mensual de febrero (1981-2010), LST (del mismo mes), X, Y, Z. Para G_dT, la anomalía es calculada como la diferencia de la normal de febrero y el valor del día/mes, se interpola mediante RSPLINES usando como covariables G_nT (regresión lineal) y X, Y, TDI (Splines). Finalmente se suma G_dT y G_nT para la temperatura grillada mensual/diaria.

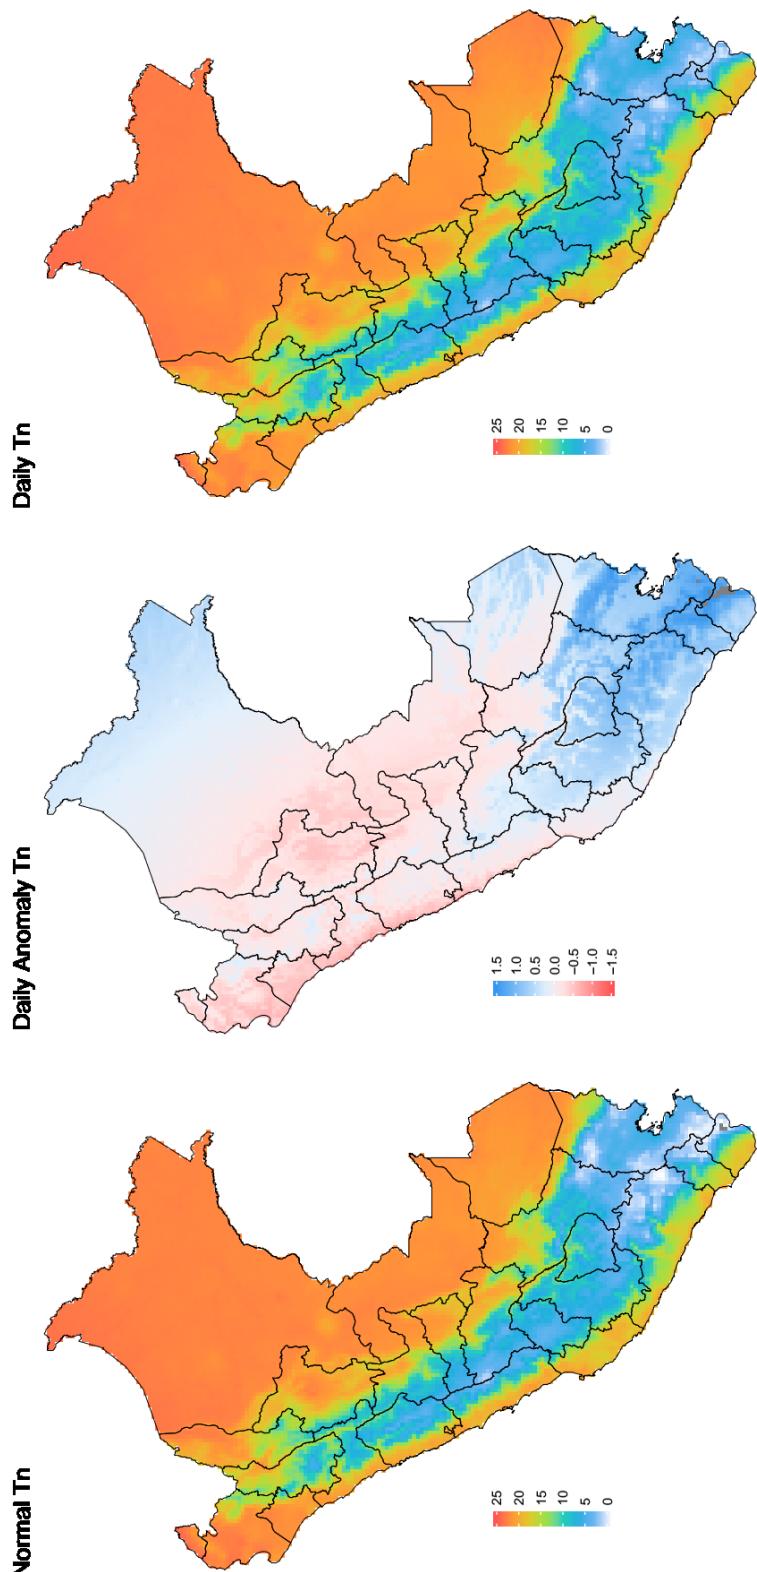


Figura 3. Estimación de la temperatura mínima diaria ($^{\circ}\text{C}$) para 04/02/1982. a) Normal de Febrero,
b) Anomalía y c) Temperatura.

Resultados preliminares

Impacto de LST en la estimación de T

En promedio, a escala nacional, LST fue un predictor ligeramente más importante que Z para la normal de Tn en la mayoría de meses (excepto Febrero). Sin embargo, ninguno alcanzó una importancia relativa de 50%, teniendo sus mayores (menores) valores en los meses de verano (invierno). Debido a la presencia de Andes, las influencias microclimáticas en Tn toman un papel importante y las inversiones de aire frío son un fenómeno común, especialmente durante los periodos de estabilidad atmosférica y enfriamiento radiativo significativo (Daly et al., 2010; Holden et al., 2011b). Por lo tanto, Tn no tiene una simple relación lineal con Z, lo que limitaría la capacidad como predictor individual para representar los patrones espaciales de Tn. La adición de LST, tiende a contribuir la estimación espacial de Tn.

A diferencia de Tn, la relativa importancia de LST en Tx es mucho menor con respecto a Z. Z tiende a contribuir en mayor (menor) medida en los verano (invierno) alcanzando valores de ~40% (30%). En cambio, LST toma importancia únicamente el periodo de otoño. Las posibles razones por la que Z es un buen predictor para Tx, es porque generalmente Tx decrece linealmente con Z (Daly et al., 2008) y la relación entre Tx y LST es mucho más compleja que con Tn (Vancutsem et al., 2010; Benali et al., 2012; Kloog et al., 2012; Oyler et al., 2015). Adicionalmente, debido a que LST solo puede ser estimado en condiciones de poca-nula nubosidad, el predictor de LST máximo está también condicionado a ese estado, cuando la diferencia entre LST máximo y Tx es generalmente mayor debido a la insolación (Jin et al., 1997).

El modelo en general evidencia una mayor capacidad predictiva global para Tn que Tx, mostrando el valor agregado de LST en Tn. Sin embargo, se debe mencionar que este análisis fue realizado a escala nacional, la contribución de cada predictor puede variar especialmente en regiones llanas y/o montañosas, esto está fuera del objetivo del estudio y está limitado fuertemente por la cantidad de estaciones.

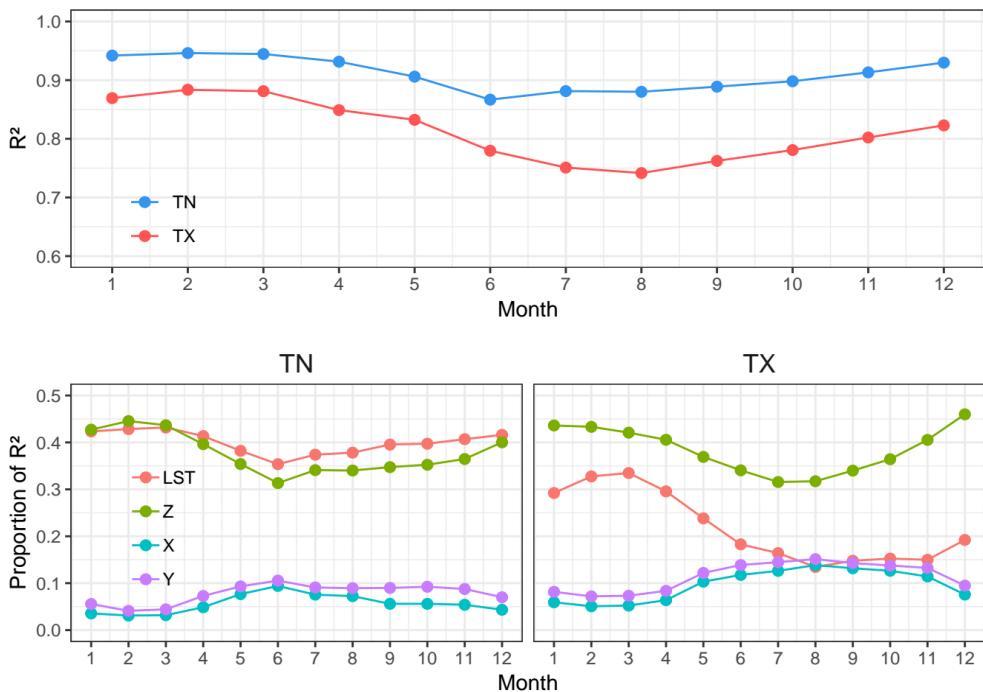


Figura 4. Estadísticos de la regresión múltiple por ventanas espaciales relacionando los predictores espaciales por GWRK (LST, Z, X e Y) y las normales de temperatura (1981-2010) a escala nacional. Arriba) Total varianza explicada (R²) y; Abajo) proporción de R² por cada predictor para cada variable. Estadísticos son promediados usando un total de 178 estaciones.

Validación cruzada

Para evaluar la eficiencia de la interpolación de T se realizó la validación cruzada dejando uno (LOOCV) en sólo aquellas estaciones que tenían más 25 años (un año con 10 meses y un mes con más del 50% de datos) (81 estaciones) con el propósito de evitar la influencia de la imputación. Este proceso fue efectuado para la interpolación de la normal climatológica, mensual y diaria. En cada iteración de LOOCV, se calculó el error simple (bias), error medio absoluto (MAE) y el índice de concordancia (d_r ; Willmott et al., 2012). Los resultados se resumieron para dos períodos: Octubre-Marzo (cálido) y Abril-Septiembre (frio).

En las normales climatológicas, los valores más altos de MAE (Figura 5) se presentan en el período frío y principalmente en Tx. Debido a la limitada cantidad de estaciones, estas caracterizan mayormente la pendiente occidental de los Andes, donde se aprecia los valores puntuales más altos de MAE en Tx y Tn, al sur y centro. Así también, se evidencia la única estación en el Amazonas (al noreste) con valor similar.

Lo anterior se aprecia claramente en el estadístico bias (Figura 6) mostrando la complejidad de la estimación de la normal T variando hasta $\pm 3^{\circ}\text{C}$. No se calculo d_r en este paso. La validación cruzada de los valores mensual/diarios (no mostrado) de T evidencian un MAE menor a 1.5°C a escala nacional y un índice de concordancia no menor a 0.6 (excepto en la estación ubicada al noreste del país) para ambos periodos.

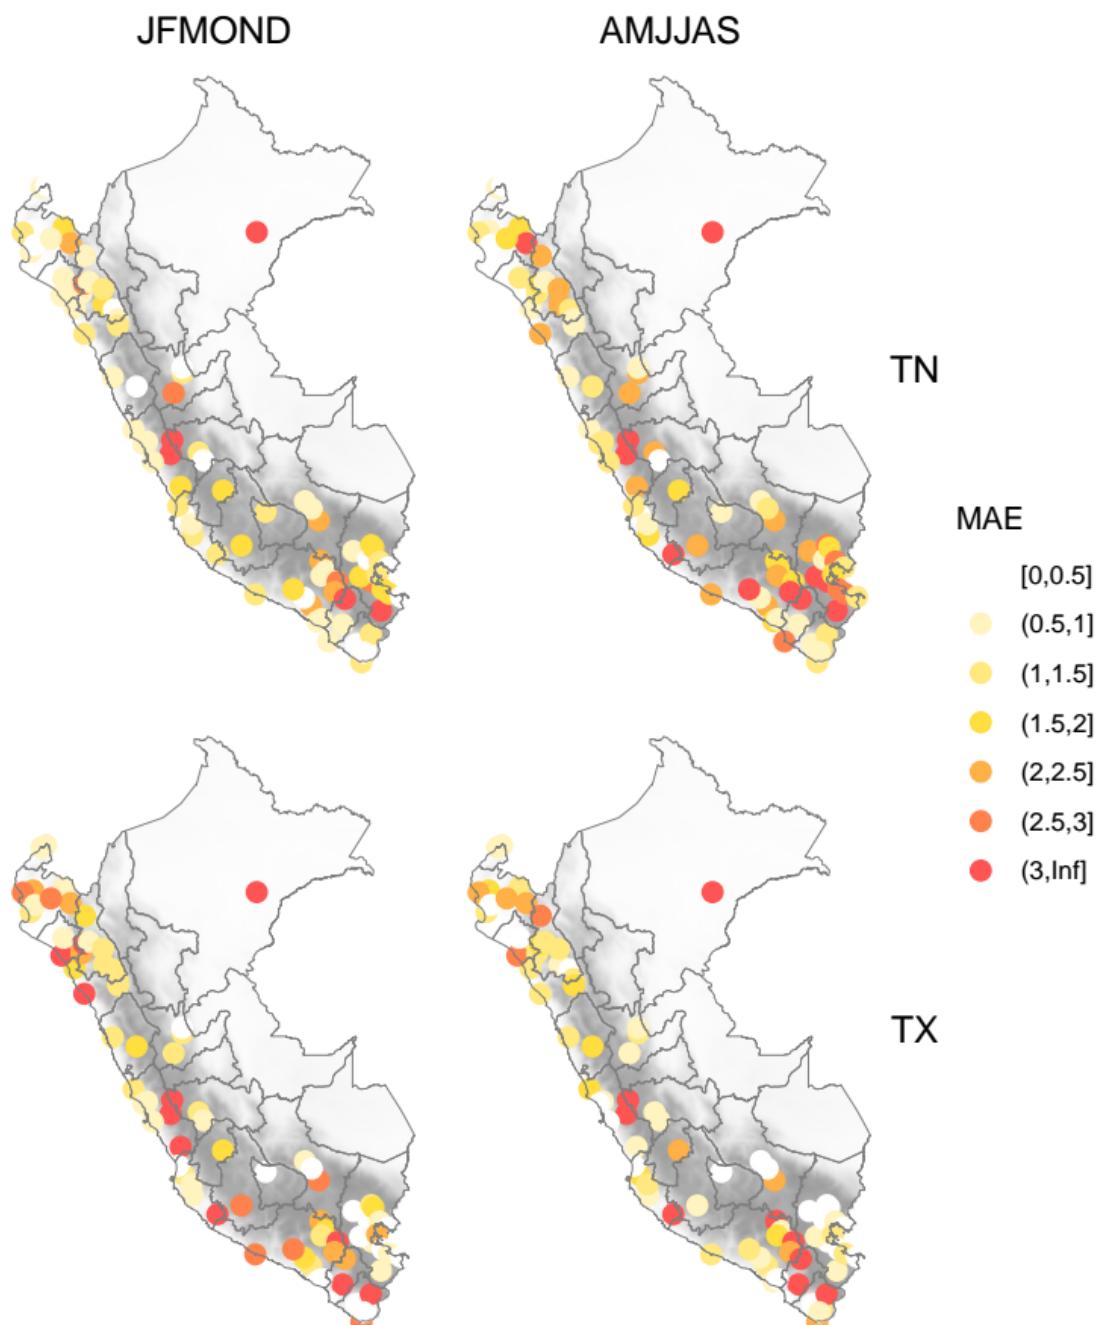


Figura 5. Resultados del estadístico MAE en la validación cruzada de los normales temperatura.

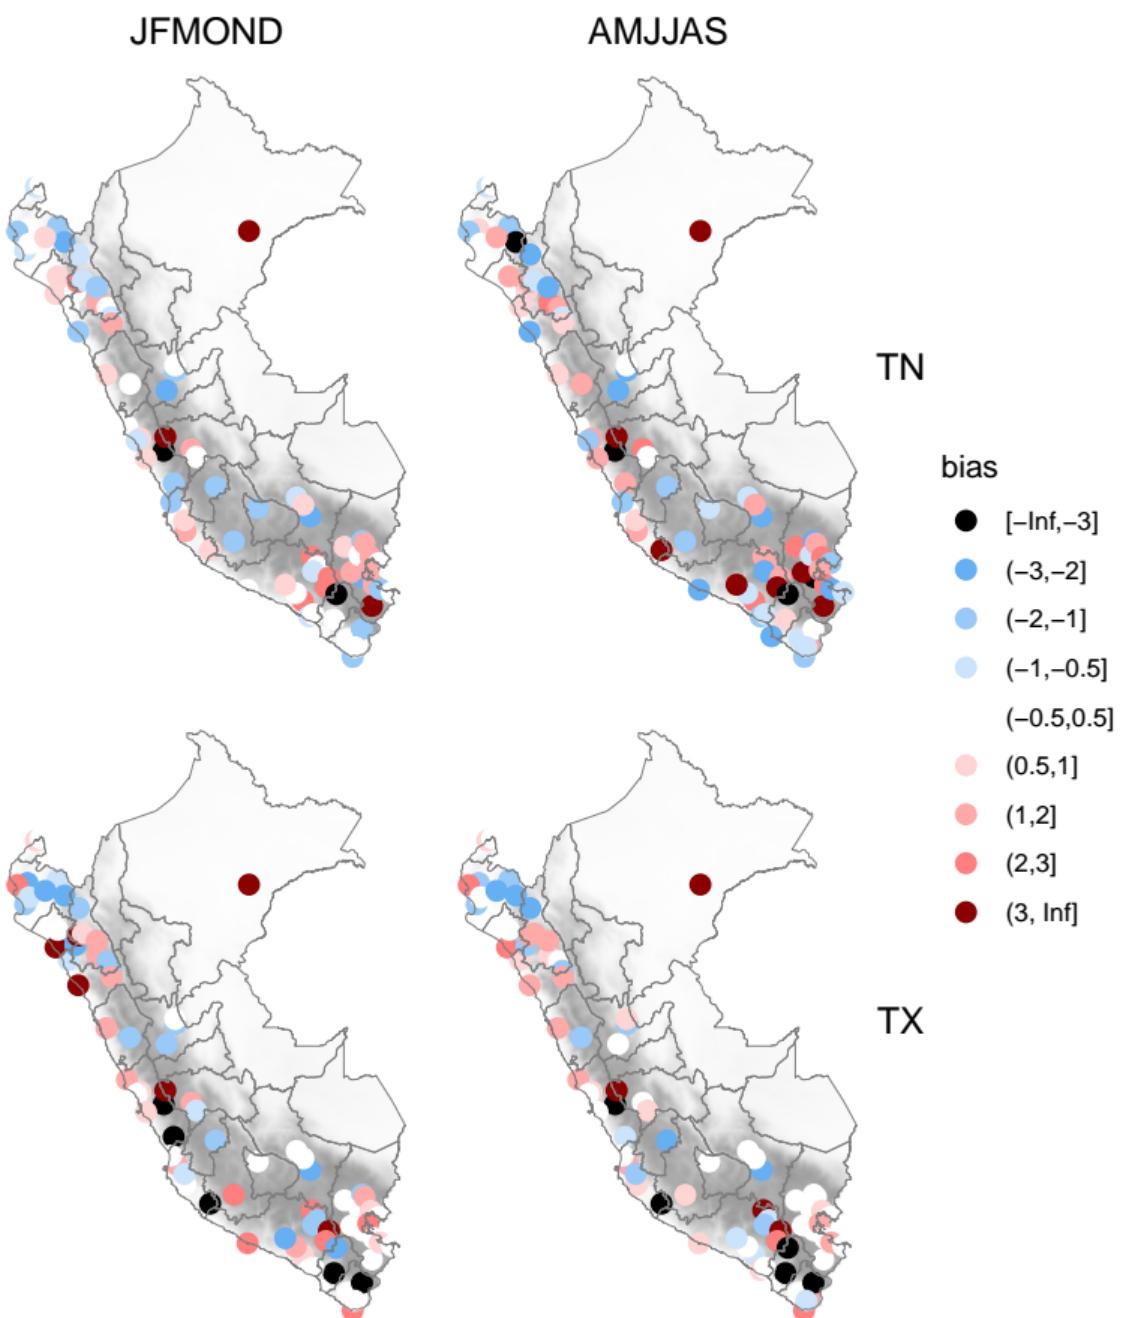


Figura 6. Resultados del estadístico bias en la validación cruzada de los normales temperatura.

Los resultados demuestran el buen rendimiento de la interpolación de PISCOt v1.1, así también caracterizan los puntos de mayor incertidumbre. Sin embargo, no se puede asumir con seguridad si la estimación es correcta en áreas lejanas a las estaciones, esto a razón de la limitada información y complejidad topográfica del área de estudio. Mayor discusiones de la validación (variabilidad, tendencias y aplicaciones) serán detallados en posteriores publicaciones de PISCOt v1.1.

Disponibilidad del producto

El producto grillado PISCOt v1.1 a una resolución de ~10km. (0.1°) y temporalmente (diario/mensual) disponible desde 1981-2016 se encuentra directamente desde el siguiente link:

- <https://drive.google.com/drive/folders/1eGqhmJXBJfFSzUFz2RVqtbKIlOphpkcs>

También puede ser accedida desde:

- <http://www.senamhi.gob.pe/?p=observacion-de-inundaciones>
- <https://github.com/adrHuerta/PISCOt>

Para más detalles de la metodología de PISCOt v1.1 se está elaborando un artículo científico para su publicación en los próximos meses. Además, la versión anterior de PISCOt v1.0 puede ser obtenida desde:

- <http://www.senamhi.gob.pe/?p=observacion-de-inundaciones>

Limitaciones y recomendaciones

La idea generalizada de comparar un producto grillado con el valor observado en un punto de estación es una medida imperfecta de eficiencia y exactitud. Es evidente que los estadísticos de eficiencia serán favorables en la comparación de información observada con productos grillados, si este último es construido con la misma información. Si el usuario usa su propia información observada (condicionado a denominarlo como valor real) sin la aplicación de los procesos de control de calidad, imputación y homogeneización para la comparación con PISCOt v1.1, los estadísticos de eficiencia serían completamente sesgados. En este contexto, la posible deficiencia del producto no está relacionado a la estimación del valor de temperatura, sino a la diferencia en la asunción del valor verdadero. Es entonces crucial saber cómo ha sido diseñado el producto grillado, así también cómo se comporta lejos de la información observada, especialmente en áreas accidentadas y complejas.

De acuerdo al análisis del usuario, algunas veces no es necesario el proceso de homogeneización. Se ha demostrado que la homogeneización tiende a suavizar las tendencias locales, forzando una tendencia regional en cada punto de pixel (Pielke et al., 2007; Walton y Hall 2018). Por lo tanto, si es necesario capturar las tendencias, se debe usar un producto grillado homogeneizado. PISCOt v1.1 es un producto homogenizado, versiones no homogeneizadas pueden ser obtenidas mediante consulta al autor.

Frecuentemente productos grillados basados en estaciones convencionales son tratados como el valor verdadero, cuando los valores observados pueden tener deficiencias. Esto es común en los Andes Centrales (Hunziker et al., 2017). Por lo tanto, los usuarios deben saber de las limitaciones. Grandes diferencias pueden ser encontradas con otros productos grillados de temperatura, por lo que su comparación está a disposición de los usuarios. Consultas y/o reporte de inconsistencias comunicarse con el autor (ahuerta@senamhi.gob.pe).

Referencias bibliográficas

1. Aguilar, E., Auer, I., Brunet, M., Thomas C, P., y Wieringa, J. (2003). Guidelines on climate metadata and homogenization. Number 1186.
2. Antolini, G., Auteri, L., Pavan, V., Tomei, F., Tomozeiu, R., y Marletto, V. (2016). A daily high-resolution gridded climatic data set for Emilia-Romagna, Italy, during 1961-2010. International Journal of Climatology, 36(4):1970-1986.
3. Aybar C., Lavado W., Huerta A., Fernandez C., Vega F. and Felipe O. (2018). PISCOp V.2.1: Construction of a High Spatial Temporal Gridded Rainfall Dataset for Peru. In preparation.
4. Benali, A., Carvalho, A. C., Nunes, J. P., Carvalhais, N. & Santos, A. Estimating air surface temperature in Portugal using MODIS LST data. Remote Sens. Environ. (2012). doi:10.1016/j.rse.2012.04.024
5. Bhaskar Rao, Srinivas, D., y Ratna, S. B. (2009). Development of a high resolution daily gridded temperature data set (1969 - 2005) for the Indian region. Atmospheric Science Letters, 10(October):249-254.
6. Caesar, J., Alexander, L., y Vose, R. (2006). Large-scale changes in observe daily maximum and minimum temperatures: Creation and analysis of a new gridded data set. Journal of Geophysical Research Atmospheres, 111(5):1-10.
7. Daly, C., Conklin, D. R. & Unsworth, M. H. Local atmospheric decoupling in complex topography alters climate change impacts. Int. J. Climatol. (2010). doi:10.1002/joc.2007
8. Dumitrescu, A. y Birisan, M. V. (2015). ROCADA: a gridded daily climatic dataset over Romania (1961{2013) for nine meteorological variables. Natural Hazards, 78(2):1045-1063.
9. Hansen, J., Ruedy, R., Sato, M., y Lo, K. (2010). Global surface temperature change. Reviews of Geophysics, 48(4):n/a{n/a. RG4004.
10. Haylock, M. R., Hofstra, N., Klein Tank, A. M. G., Klok, E. J., Jones, P. D., y New, M. (2008). A European daily high-resolution gridded data set of surface temperature and precipitation for 1950-2006. Journal of Geophysical Research Atmospheres, 113(20).
11. Herrera, S., Fernandez, J., y Gutierrez, J. M. (2016). Update of the Spain02 gridded observational dataset for EURO-CORDEX evaluation: Assessing the effect of the interpolation methodology. International Journal of Climatology, 36(2):900-908.
12. Hiebl, J. y Frei, C. (2016). Daily temperature grids for Austria since 1961: concept, creation and applicability. Theoretical and Applied Climatology, 124(1-2):161-178.

13. Holden, Z. A., Abatzoglou, J. T., Luce, C. H. & Baggett, L. S. Empirical downscaling of daily minimum air temperature at very fine resolutions in complex terrain. *Agric. For. Meteorol.* (2011a). doi:10.1016/j.agrformet.2011.03.011.
14. Holden, Z. A., Crimmins, M. A., Cushman, S. A. & Littell, J. S. Empirical modeling of spatial and temporal variation in warm season nocturnal air temperatures in two North Idaho mountain ranges, USA. *Agric. For. Meteorol.* (2011b). doi:10.1016/j.agrformet.2010.10.006
15. Hunziker, S., Gubler, S., Calle, J., Moreno, I., Andrade, M., Velarde, F., Ticona, L., Carrasco, G., Castellón, Y., Oria, C., Croci-Maspoli, M., Konzelmann, T., Rohrer, M., Brönnimann, S. Identifying, attributing, and overcoming common data quality issues of manned station observations. (2017). doi:10.1002/joc.5037
16. Hunziker, S., Brönnimann, S., Calle, J., Moreno, I., Andrade, M., Ticona, L., Huerta, A., Lavado-Casimiro, W. Effects of undetected data quality issues on climatological analyses. *Clim. Past* 14, 1–20 (2018).
17. Jin, M., Dickinson, R. E. & Vogelmann, A. M. A comparison of CCM2-BATS skin temperature and surface-air temperature with satellite and surface observations. *Journal of Climate* (1997). doi:10.1175/1520-0442(1997)010<1505:ACOCBS>2.0.CO;2
18. Kilibarda, M., Hengl, T., Heuvelink, G. B. M., Graler, B., Pebesma, E., Percec Tadic, M., y Bajat, B. (2014). Spatio-temporal interpolation of daily temperatures for global land areas at 1km resolution. *Journal of Geophysical Research: Atmospheres*, 119(5):2294-2313.
19. Kloog, I., Chudnovsky, A., Koutrakis, P. & Schwartz, J. Temporal and spatial assessments of minimum air temperature using satellite surface temperature measurements in Massachusetts, USA. *Sci. Total Environ.* (2012). doi:10.1016/j.scitotenv.2012.05.095
20. Menne, M. J. y Williams, C. N. (2009). Homogenization of temperature series via pairwise comparisons. *Journal of Climate*, 22(7):1700-1717.
21. Morice, C. P., Kennedy, J. J., Rayner, N. A., y Jones, P. D. (2012). Quantifying uncertainties in global and regional temperature change using an ensemble of observational estimates: The hadcrut4 data set. *Journal of Geophysical Research: Atmospheres*, 117(D8):n/a{n/a}. D08101.
22. Oyler, J. W., Ballantyne, A., Jencso, K., Sweet, M., y Running, S. W. (2015). Creating a topoclimatic daily air temperature dataset for the conterminous united states using homogenized station data and remotely sensed land skin temperature. *International Journal of Climatology*, 35(9):2258-2279.

23. Pielke, R. A. et al. Unresolved issues with the assessment of multidecadal global land surface temperature trends. *J. Geophys. Res. Atmos.* 112, (2007).
24. Skansi, M. d. l. M., Brunet, M., Sigró, J., Aguilar, E., Arevalo Groening, J. A., Bentancur, O. J., Castellón Geier, Y. R., Correa Amaya, R. L., Jácome, H., Malheiros Ramos, A., Oria Rojas, C., Pasten, A. M., Sallons Mitro, S., Villaroel Jiménez, C., Martínez, R., Alexander, L. V., y Jones, P. D. (2013). Warming and wetting signals emerging from analysis of changes in climate extreme indices over South America. *Global and Planetary Change*, 100:295-307.
25. Vancutsem, C., Ceccato, P., Dinku, T. & Connor, S. J. Evaluation of MODIS land surface temperature data to estimate air temperature in different ecosystems over Africa. *Remote Sens. Environ.* (2010). doi:10.1016/j.rse.2009.10.002
26. Vicente-Serrano, S. M. et al. Recent changes in monthly surface air temperature over Peru, 1964–2014. *Int. J. Climatol.* (2018). doi:10.1002/joc.5176
27. Vincent, L. A., Zhang, X., Bonsal, B., y Bonsal, W. (2002). Homogenization of daily temperatures over canada. *Journal of Climate*, 1322-1334.
28. Xavier, A. C., King, C. W., y Scanlon, B. R. (2015). Daily gridded meteorological variables in Brazil (1980-2013). *International Journal of Climatology*, 2659(October 2015):2644-2659.
29. Walton, D. & Hall, A. An assessment of high-resolution gridded temperature datasets over California. *J. Clim.* 31, 3789–3810 (2018).
30. Wan, Z., Zhang, Y., Zhang, Q., y Li, Z.-L. (2004). Quality assessment and validation of the modis global land surface temperature. *International Journal of Remote Sensing*, 25(1):261-274
31. Willmott, C. J., Robeson, S. M. & Matsuura, K. A refined index of model performance. *Int. J. Clim.* 32, 2088–2094 (2012).